

| 01 信源

| 信源

| 有记忆/无记忆信源

区分有记忆信源和无记忆信源，核心看消息之间是否存在依赖关系。

无记忆信源中，各个符号相互独立，因此有：

$$P(\bar{X}) = P(X_1 X_2 \dots X_N) = P(X_1)P(X_2) \dots P(X_N)$$

有记忆信源中，当前信息会依赖之前的信息。

| 平稳/非平稳信源

区分平稳信源和非平稳信源，核心看统计特性是否保持不变。

若信源平稳，任意维度的联合概率都与时间起点无关：

$$P(X_i) = P(X_j)$$

$$P(X_i X_{i+1} \dots X_{i+N}) = P(X_j X_{j+1} \dots X_{j+N})$$

| 信源

本课只讨论离散信源，通常用随机变量描述信源：

$$\begin{bmatrix} X \\ P(X) \end{bmatrix} = \begin{bmatrix} X = x_1 & \dots & X = x_i & \dots & X = x_n \\ p(x_1) & \dots & p(x_i) & \dots & p(x_n) \end{bmatrix}$$

概率分布需要满足归一化条件：

$$\sum p(x_i) = 1$$

| 信息熵

| 自信息

自信息描述单个随机事件所携带的信息量：

$$I(x_i) = -\log p(x_i) = \log \frac{1}{p(x_i)}$$

物理意义可以从三个角度理解：

- 事件发生前：事件发生的不确定性的的大小。
- 事件发生后：事件中所含有的信息量。
- 理想信道中：受信者接受消息后所获取的信息量。

自信息的单位是比特 (bit)。

联合自信息定义为：

$$I(x_i y_j) = -\log p(x_i y_j)$$

条件自信息定义为：

$$I(x_i | y_j) = -\log p(x_i | y_j)$$

由联合概率分解可以得到：

$$\begin{aligned} I(x_i y_j) &= -\log p(x_i y_j) = -\log p(x_i) p(y_j | x_i) = I(x_i) + I(y_j | x_i) \\ &= -\log p(y_j) p(x_i | y_j) = I(y_j) + I(x_i | y_j) \end{aligned}$$

信息熵

自信息是对单个随机事件而言，信息熵则描述整个信源的不确定度。它等于信源所有事件自信息的期望，也就是平均自信息：

$$H(X) = E[I(x_i)] = \sum_{i=1}^n p(x_i) I(x_i) = - \sum_{i=1}^n p(x_i) \log p(x_i)$$

信息熵的单位是比特/符号 (bit/symbol)。

信息熵的常见理解：

- 在信源输出前，表示信源的平均不确定性。
- 在信源输出后，表示每个消息符号给出的平均消息量。
- 也可以表示变量 X 的随机性大小或最小描述复杂度。

信息熵的性质

对称性

对于概率矢量 $P(p_1, p_2, \dots, p_q)$ 的任意排列，熵函数的值不变。

这说明熵只与随机变量的总体结构、信源的统计特性有关。如果两个信源含有的符号数和概率分布相同，那么它们的熵相同。

确定性

如果某个事件必然发生，其它事件不可能发生，则信源没有不确定性，熵为 0:

$$H(1, 0) = H(1, 0, 0) = \dots = H(1, 0, \dots, 0) = 0$$

非负性

离散信源的熵总是非负的:

$$H(P) = H(p_1, p_2, \dots, p_q) \geq 0$$

扩展性

给信源增加一个概率趋近于 0 的事件时，信源熵保持不变:

$$\lim_{\varepsilon \rightarrow 0} H(p_1, p_2, \dots, p_q - \varepsilon, \varepsilon) = H(p_1, p_2, \dots, p_q)$$

强可加性

考虑两个相互关联的随机变量 X 和 Y :

$$\begin{bmatrix} X \\ P(X) \end{bmatrix} = \begin{bmatrix} x_1 & x_2 & \dots & x_n \\ p(x_1) & p(x_2) & \dots & p(x_n) \end{bmatrix} \quad 0 \leq p(x_i) \leq 1 \quad \sum_{i=1}^n p(x_i) = 1$$

$$\begin{bmatrix} Y \\ P(Y) \end{bmatrix} = \begin{bmatrix} y_1 & y_2 & \dots & y_n \\ p(y_1) & p(y_2) & \dots & p(y_n) \end{bmatrix} \quad 0 \leq p(y_i) \leq 1 \quad \sum_{i=1}^n p(y_i) = 1$$

相互关联表示联合概率可以写成:

$$p(x_i y_j) = p(x_i) p(y_j | x_i)$$

对 $H(XY)$ 进行推导:

$$\begin{aligned} H(XY) &= - \sum_i \sum_j p(x_i y_j) \log p(x_i y_j) \\ &= - \sum_i \sum_j p(x_i y_j) \log p(x_i) - \sum_i \sum_j p(x_i y_j) \log p(y_j | x_i) \\ &= - \sum_i p(x_i) \log p(x_i) \sum_j p(y_j | x_i) - \sum_i p(x_i) \sum_j p(y_j | x_i) \log p(y_j | x_i) \\ &= - \sum_i p(x_i) \log p(x_i) - \left\{ \sum_i p(x_i) \left[- \sum_j p(y_j | x_i) \log p(y_j | x_i) \right] \right\} \\ &= H(X) + \sum_i p(x_i) H(Y | x_i) \\ &= H(X) + H(Y | X) \end{aligned}$$

由此可以得到联合熵、条件熵和链式规则。

联合熵定义为：

$$H(XY) = E[I(x_i y_j)] = \sum_{XY} p(x_i y_j) \times I(x_i y_j) = - \sum_{XY} p(x_i y_j) \log p(x_i y_j)$$

物理意义：在 X 和 Y 相关联的情况下，信源 (XY) 每发一个符号所能提供的平均信息量，等于信源 X 每发一个符号所能提供的平均信息量，再加上在 X 已知的条件下，信源 Y 再发一个符号所提供的平均信息量。

条件熵定义为：

$$H(Y|X) = E[I(y_j|x_i)] = \sum_{XY} \underline{p(x_i y_j)} \times I(y_j|x_i) = - \sum_{XY} p(x_i y_j) \log p(y_j|x_i)$$

物理意义：已知（已收到）集合 X 后，集合 Y 仍然存在的平均不确定性；也可以理解为在 X 平均每发一个符号的前提下， Y 平均每发一个符号额外能提供的信息量。

条件熵也常写成：

$$H(Y|X) = \sum_i p(x_i) H(Y|x_i)$$

若 X 与 Y 相互独立，则：

$$H(XY) = H(X) + H(Y)$$

链式规则为：

$$H(X_1 X_2 \dots X_N) = H(X_1) + H(X_2|X_1) + H(X_3|X_1 X_2) + \dots + H(X_N|X_1 X_2 \dots X_{N-1})$$

| 上凸性

熵函数是严格上凸函数。

| 证明

① 引理：詹森不等式

若 $f(x)$ 是定义在区间 $[a, b]$ 上的实值连续上凸函数，则对于任意一组 $x_1, x_2, \dots, x_q \in [a, b]$ 和任意一组非负实数 $\lambda_1, \lambda_2, \dots, \lambda_q$ 满足 $\sum_{k=1}^q \lambda_k = 1$ ，我们有

$$f\left[\sum_{k=1}^q \lambda_k x_k\right] \geq \sum_{k=1}^q \lambda_k f(x_k)$$

詹森不等式可以理解为：对于一个凸函数而言，期望的函数大于等于函数的期望：

$$f(E[x_i]) \geq E[f(x_i)]$$

在熵函数中， $f() = \log()$ ，而 $\log(x)$ 是上凸函数，所以：

$$\log(E[x]) \geq E[\log x]$$

因此可以得到 $H(X)$ 为上凸函数。

极值性

最大离散熵定理：对于一个输出 n 个不同信息符号的离散无记忆信源，当且仅当各个符号出现概率相等时，即 $p_i = \frac{1}{n}$ ，熵最大。

$$H(P) = H(p_1, p_2, \dots, p_n) \leq H\left(\frac{1}{n}, \frac{1}{n}, \dots, \frac{1}{n}\right) = \log n$$

离散无记忆信源

扩展信源

考虑一个随机矢量或随机序列：

$$X = X_1 X_2 X_3 \dots$$

这里通常假定：

- 符号序列中各符号彼此无关，即无记忆。
- 符号序列中各符号取自同一符号集，即具有相同概率空间。

由此可以建立 N 次扩展信源模型：

$$\begin{bmatrix} X^N \\ P(\vec{X}) \end{bmatrix} = \begin{bmatrix} \alpha_1 & \dots & \alpha_{q^N} \\ p(\alpha_1) & \dots & p(\alpha_{q^N}) \end{bmatrix}$$

其中：

$$p(\alpha_i) = p(x_{i_1})p(x_{i_2}) \dots p(x_{i_N}) = \prod p_{i_k}$$

信源 X 与扩展信源 X^N 之间满足：

$$H(X^N) = NH(X)$$

离散平稳信源

实际生活中大部分信源是有记忆信源。为了便于研究，通常假定在一个短时间内信源是平稳信源。

核心物理量

联合熵（矢量熵） 描述信源平均每发送一个长度为 N 的消息序列所提供的信息量：

$$H(\vec{X}) = H(X_1 X_2 \dots X_N)$$

平均符号熵 描述当序列长度为 N 时，信源平均每发出一个符号提供的信息量：

$$H_N(\vec{X}) = \frac{1}{N} H(X_1 X_2 \dots X_N)$$

极限熵（熵率） 是当记忆长度无限延伸时，平均符号熵的极限值：

$$H_\infty = \lim_{N \rightarrow \infty} H_N(\vec{X})$$

三条基本性质

1. 随着已知关联历史（条件）的增长，各阶条件熵单调递减：

$$H(X_N | X_1 \dots X_{N-1}) \leq H(X_{N-1} | X_1 \dots X_{N-2})$$

2. 在记忆长度相同时，平均符号熵大于等于最新一阶的条件熵：

$$H_N(\vec{X}) \geq H(X_N | X_1 \dots X_{N-1})$$

3. 平均符号熵随 N 增加是非递增的，且有界：

$$H_N(\vec{X}) \leq H_{N-1}(\vec{X}), \quad 0 \leq H_N(\vec{X}) \leq H_1(X) < \infty$$

极限熵的存在性与求法

对于任意离散平稳信源，只要 $H_1(X) < \infty$ ，极限熵必然存在：

$$H_\infty = \lim_{N \rightarrow \infty} H_N(\vec{X}) = \lim_{N \rightarrow \infty} H(X_N | X_1 \dots X_{N-1})$$

若信源的记忆深度为有限的 m 阶（ $m+1$ 维平稳信源），当 $N \geq m+1$ 时，极限熵退化为有限阶条件熵：

$$H_{\infty} = H(X_{m+1}|X_1 X_2 \dots X_m)$$

| 马尔可夫信源

马尔可夫信源指：某一时刻发出某一符号的概率，仅与此前发出的有限个符号有关。

m 阶马氏信源中，当前符号仅依赖于前 m 个符号。

| 马尔可夫链与状态转移矩阵

时齐马氏链指状态转移概率不随时间起点发生改变：

$$p_{ij}(m) = P(X_{m+1} = S_j | X_m = S_i) = p_{ij}$$

一步转移概率矩阵 P 写作：

$$P = \begin{bmatrix} p_{11} & p_{12} & \dots & p_{1J} \\ p_{21} & p_{22} & \dots & p_{2J} \\ \vdots & \vdots & \ddots & \vdots \\ p_{J1} & p_{J2} & \dots & p_{JJ} \end{bmatrix}$$

转移矩阵的每个元素非负，各行元素之和为 1，即 $\sum_j p_{ij} = 1$ 。

对于时齐马氏链， k 步转移概率由一步转移概率完全决定，这就是 C-K 方程：

$$P^{(k)} = P^k$$

| 各态历经性与稳态分布

有限状态的时齐马氏链若不可约、非周期，且存在 r 使 P^r 中所有元素均大于 0，则满足遍历性条件。

遍历马氏链在 $n \rightarrow \infty$ 时，状态概率会收敛到与初始分布无关的稳态分布：

$$W = [W_1, W_2, \dots, W_J]$$

稳态分布通过下面的方程组求解：

$$\begin{cases} WP = W \\ \sum_{j=1}^J W_j = 1 \end{cases}$$

| m 阶马氏信源的极限熵

m 阶马氏信源可以等效为有 q^m 个状态的时齐马氏链。达到稳态后：

$$H_{\infty} = - \sum_{i=1}^J P(S_i) \sum_{k=1}^q p(x_k|S_i) \log p(x_k|S_i)$$

其中：

- $P(S_i)$ 是状态 S_i 的平稳概率，由 $WP = W$ 解得。
- $p(x_k|S_i)$ 是在状态 S_i 下输出符号 x_k 的条件概率。

标准解题步骤

1. 由条件概率表写出一步状态转移矩阵 P ，画出状态转移图
 - 注意区分"符号条件概率"与"状态转移"——状态转移必须满足符号拼接逻辑
2. 验证极限分布是否存在：计算 P^2 或 P^3 ，检查是否所有元素大于 0。
3. 联立 $WP = W$ 与 $\sum W_i = 1$ 求解稳态概率分布 W 。
4. 套用极限熵公式求 H_{∞} 。
5. （如需）利用全概率公式计算平稳后的单符号极限分布：

$$P(x_k) = \sum_{S_i} P(S_i)P(x_k|S_i)$$

信源的相关性与冗余度

相关性对熵的影响

不同记忆长度下，同一信源的熵满足：

$$H_0 \geq H_1 \geq H_2 \geq \dots \geq H_{m+1} \geq \dots \geq H_{\infty}$$

各项含义如下：

- $H_0 = \log q$ ：无记忆等概率下的最大熵。
- H_1 ：无记忆但考虑符号实际分布概率。
- H_m ：考虑前 $m - 1$ 个符号关联的条件熵。
- H_{∞} ：实际信源熵。

核心结论：符号间相关性越大，信源的实际有效熵 H_{∞} 就越小。

冗余度

实际信源存在相关性。若只用 H_1 甚至 H_0 的方案传输，会造成传输资源的富余，也就是存在可压缩空间。

熵的相对率定义为：

$$\eta = \frac{H_{\infty}}{H_0}$$

信源冗余度（剩余度）定义为：

$$R = 1 - \eta = \frac{H_0 - H_{\infty}}{H_0}$$

自然语言（英文）冗余度实例

- $q = 27$ (26 个字母 + 1 个空格)
- $H_0 = \log_2 27 \approx 4.76 \text{ bit/symbol}$
- $H_1 \approx 4.03 \text{ bit/symbol}$ (考虑字母出现概率)
- $H_{\infty} \approx 1.4 \text{ bit/symbol}$ (高阶马氏信源逼近)
- 冗余度: $R = \frac{4.76-1.4}{4.76} \approx 71\%$

物理意义：

- 英文文章中 71% 由语言结构规范（语法、拼写习惯）决定，写作者自由选择的部分仅占 29%。
- 通过无失真信源编码，理论上可压缩掉 71% 的体积。
- 冗余度的双重作用：降低传输效率，但赋予语言抗干扰能力，受信者可根据上下文纠错。