

编码

1 编码

本章讨论的是无失真信源编码：在不丢失信源信息的前提下，尽量去掉信源冗余，使传输或存储更有效。

1.1 变量约定

- 信源符号集大小： $q = |S|$
- 码元符号集大小： $r = |X|$
- 定长码的码长： l

NOTE

若无特别说明， $\log$ 默认以 2 为底，信息量单位为 bit；码元进制为 r 时，每个码元最多承载 $\log r$ bit 信息。

1.2 为什么要编码

信源中常常存在冗余。信源编码的目的，是把信源符号序列映射成码符号序列，通过压缩冗余来提高传输效率。

信源的统计冗余主要来自两个方面：

- 符号间相关性：当前符号可以被前后符号部分预测。
- 概率分布不均匀性：某些符号出现概率远大于另一些符号。

信源越独立、均匀，冗余度越低；信源越有记忆、越不均匀，可压缩空间越大。

1.3 信源编码模型

信源编码是将信源符号序列按一定数学规则映射成码符号序列的过程，例如摩斯电码。


$$\begin{array}{ccccc} \text{信源符号集} & & \text{码元符号集} & & \text{码组} \\ S = \{s_1, s_2, \dots, s_q\} & \xrightarrow{\quad} & X = \{x_1, x_2, \dots, x_r\} & \xrightarrow{\quad} & C = \{W_1, W_2, \dots, W_q\} \end{array}$$

其中：

$$W_i = x_{i1}x_{i2} \cdots x_{il_i}$$

W_i 称为码字, l_i 称为码长。对 N 次扩展信源, 也可以建立 $S^N \leftrightarrow W^N$ 的映射。

1.4 码的分类



1.4.1 分组码

分组码把每个信源符号 s_i 映射成一个码字 W_i 。如果不同信源符号可能映射到同一个码字, 则会产生译码歧义。

1.4.2 奇异码与非奇异码

- 奇异码: 至少存在两个不同信源符号对应同一个码字。
- 非奇异码: 每个信源符号对应不同码字。

非奇异码只保证单个码字不混淆, 不一定保证一串码字连接起来后仍能唯一拆分。

1.4.3 唯一可译码

唯一可译码要求任意有限长的码符号序列, 最多只能被译成一种信源符号序列。

充要条件:

- 一个码是唯一可译码, 当且仅当它的任意次扩展码都是非奇异码。

重要结论:

- 非奇异码不一定是唯一可译码。
- 等长非奇异码一定是唯一可译码, 因为码字边界固定。

常用判别思路是构造后缀集合 (Sardinas-Patterson 判别法):

- 若迭代过程中出现空后缀, 或某个后缀恰好等于原码字, 则该码不是唯一可译码。
- 若后缀集合不再产生新元素, 且始终没有出现冲突, 则该码是唯一可译码。

1.4.4 即时码

即时码也叫前缀码。接收端在读到一个完整码字时，不需要参考后续码元就可以立即译码。

充要条件：

- 码组中任意一个码字都不是另一个码字的前缀。

例如 $C = \{0, 01\}$ 不是即时码。接收到 0 时，无法判断它就是码字 0，还是码字 01 的开头。

即时码可以用 r 进制码树构造：每个码字对应树上的一个叶节点，不能让某个码字落在另一个码字的祖先节点上。

1.5 定长码

定长码要求所有码字长度相同，设码长为 l 。若要把 q 个信源符号编码成 r 元非奇异码，必须满足：

$$r^l \geq q$$

对 N 次扩展信源 S^N 做定长编码时，信源序列共有 q^N 种，因此需要：

$$r^l \geq q^N$$

也就是：

$$\frac{l}{N} \geq \log_r q = \frac{\log q}{\log r}$$

1.6 平均码长与最佳码

对变长码而言，不同信源符号可以使用不同长度的码字。平均码长定义为：

$$\bar{L} = \sum_{i=1}^q p(s_i) l_i \quad \text{码元/信源符号}$$

在所有满足无失真要求的码中，平均码长最小的码称为最佳码，也常称紧致码。

1.7 定长编码定理

对离散无记忆信源 S 的 N 次扩展信源 S^N 进行 l 长定长编码。对于任意 $\varepsilon > 0$ ，只要满足：

$$\frac{l}{N} \geq \frac{H(S) + \varepsilon}{\log r}$$

当 $N \rightarrow \infty$ 时，就可以做到几乎无失真编码。

这里的“几乎无失真”不是完全无误，而是译码错误概率趋于 0。

1.7.1 证明思路：典型序列

先使用渐进均分性定理 (AEP)：

$$\lim_{N \rightarrow \infty} P \left\{ \left| -\frac{1}{N} \log P(X^N) - H(S) \right| < \varepsilon \right\} = 1$$

它说明当 N 足够大时，大部分概率质量集中在一批典型序列上。这些序列满足：

$$P(x^N) \approx 2^{-NH(S)}$$

因此典型序列个数大约为：

$$M_G \approx 2^{NH(S)}$$

1.7.2 为什么编码后近乎等概分布

AEP 不只是说“典型序列很多”，更关键的是说：当 N 足够大时，真正可能出现的大部分序列都落在典型集中，并且每个典型序列的概率都近似为：

$$P(x^N) \approx 2^{-NH(S)}$$

也就是说，原信源单个符号可能很不均匀，但把它拉成长序列后，在承载主要概率质量的典型集中，各个典型序列几乎等概率。信源编码主要给这些典型序列分配码字，因此编码后的码字被选中的概率也近乎相等。

从冗余角度看，如果编码输出仍然明显不均匀或有相关性，就说明输出里还保留着可预测结构，还可以继续压缩。理想的高效信源编码会把这些冗余尽量去掉，使码元序列接近独立、等概分布；这时每个码元平均承载的信息量才接近最大值 $\log r$ 。

更精确地说，在 ε 典型集 G_ε 中，典型序列个数可由 $2^{N[H(S)+\varepsilon]}$ 控制。只对典型序列进行定长编码，只需满足：

$$r^l \geq M_G$$

于是：

$$r^l \geq 2^{N[H(S)+\varepsilon]}$$

两边取对数：

$$l \log r \geq N[H(S) + \varepsilon]$$

得到：

$$\frac{l}{N} \geq \frac{H(S) + \varepsilon}{\log r}$$

非典型序列被舍弃。虽然它们一旦出现就会译码错误，但当 $N \rightarrow \infty$ 时，非典型序列的总概率趋于 0，因此错误概率：

$$p_E = P(\overline{G_\varepsilon}) \rightarrow 0$$

对于离散有记忆信源，也有类似结论，但应把 $H(S)$ 换为极限熵 H_∞ 。

NOTE：典型序列概率的推导

对无记忆信源：

$$P(x^N) = \prod_{i=1}^N P(x_i)$$

取对数并除以 N ：

$$-\frac{1}{N} \log P(x^N) = \frac{1}{N} \sum_{i=1}^N [-\log P(x_i)]$$

当 $N \rightarrow \infty$ 时，由大数定律：

$$\frac{1}{N} \sum_{i=1}^N [-\log P(x_i)] \rightarrow E[-\log P(X)] = H(S)$$

所以典型序列满足：

$$P(x^N) \approx 2^{-NH(S)}$$

1.8 变长码

变长码通过给高概率符号分配短码字、给低概率符号分配长码字来降低平均码长。

1.8.1 Kraft 不等式

存在一个 r 元即时码，其码长为 $l_1, l_2, \dots, l_q$ 的充分必要条件是：

$$\sum_{i=1}^q r^{-l_i} \leq 1$$

1.8.2 McMillan 不等式

任意 r 元唯一可译码的码长都满足：

$$\sum_{i=1}^q r^{-l_i} \leq 1$$

反过来，只要一组码长满足这个不等式，就一定能构造出一组具有相同码长的即时码，因此也能构造唯一可译码。

WARNING

Kraft/McMillan 不等式主要判断的是码长集合是否可行。

对某一个已经给出的具体码组，满足不等式不代表它本身一定是即时码或唯一可译码；但不满足不等式时，它一定不可能是即时码或唯一可译码。

1.9 编码信息率与编码效率

编码信息率表示平均每个码元实际承载的信源信息量：

$$R = \frac{H(S)}{\bar{L}} \quad \text{bit/码元}$$

由于 r 元码的每个码元最多承载 $\log r$ bit，编码效率为：

$$\eta = \frac{R}{\log r} = \frac{H(S)}{\bar{L} \log r} = \frac{H_r(S)}{\bar{L}}$$

其中：

$$H_r(S) = \frac{H(S)}{\log r}$$

信源编码的目标可以理解为：减小 $\bar{L}$ ，提高 R 和 η 。

1.10 平均码长界限定理

总可以找到一种无失真信源编码，构成唯一可译码，使平均码长满足：

$$\frac{H(S)}{\log r} \leq \bar{L} < \frac{H(S)}{\log r} + 1$$

该定理说明：

- 平均码长的理论下界是 $H_r(S) = \frac{H(S)}{\log r}$ 。
- 单符号变长编码最多只比熵限多不到 1 个码元。
- 这里是完全无失真编码，不是“几乎无失真”。

1.10.1 下界证明

由平均码长定义：

$$\begin{aligned} H(S) - \bar{L} \log r &= - \sum_{i=1}^q p(s_i) \log p(s_i) - \sum_{i=1}^q p(s_i) l_i \log r \\ &= - \sum_{i=1}^q p(s_i) \log p(s_i) + \sum_{i=1}^q p(s_i) \log r^{-l_i} \\ &= \sum_{i=1}^q p(s_i) \log \frac{r^{-l_i}}{p(s_i)} \end{aligned}$$

利用 $\log$ 函数的上凸性 (Jensen 不等式):

$$\begin{aligned}\sum_{i=1}^q p(s_i) \log \frac{r^{-l_i}}{p(s_i)} &\leq \log \sum_{i=1}^q p(s_i) \frac{r^{-l_i}}{p(s_i)} \\ &= \log \sum_{i=1}^q r^{-l_i} \\ &\leq 0\end{aligned}$$

因此:

$$H(S) - \bar{L} \log r \leq 0$$

所以:

$$\bar{L} \geq \frac{H(S)}{\log r}$$

1.10.2 上界构造

取码长:

$$l_i = \lceil -\log_r p(s_i) \rceil$$

则:

$$-\log_r p(s_i) \leq l_i < -\log_r p(s_i) + 1$$

两边乘以 $p(s_i)$ 后求和:

$$\frac{H(S)}{\log r} \leq \bar{L} < \frac{H(S)}{\log r} + 1$$

同时这组码长满足 Kraft 不等式, 因此可以构造即时码。

1.11 香农第一定理

香农第一定理也叫变长无失真信源编码定理。

对离散无记忆信源的 N 次扩展信源 S^N 进行编码, 总能找到一种唯一可译码, 使:

$$\frac{H(S)}{\log r} \leq \frac{\bar{L}_N}{N} < \frac{H(S)}{\log r} + \frac{1}{N}$$

证明很直接: 把 S^N 看作一个新信源, 套用平均码长界限定理:

$$\begin{aligned}\frac{H(S^N)}{\log r} &\leq \overline{L_N} < \frac{H(S^N)}{\log r} + 1 \\ \frac{NH(S)}{\log r} &\leq \overline{L_N} < \frac{NH(S)}{\log r} + 1 \\ \frac{H(S)}{\log r} &\leq \frac{\overline{L_N}}{N} < \frac{H(S)}{\log r} + \frac{1}{N}\end{aligned}$$

当 $N \rightarrow \infty$ 时:

$$\lim_{N \rightarrow \infty} \frac{\overline{L_N}}{N} = \frac{H(S)}{\log r} = H_r(S)$$

推广到一般离散平稳信源:

$$\lim_{N \rightarrow \infty} \frac{\overline{L_N}}{N} = \frac{H_\infty}{\log r}$$

这说明:

- 对无记忆信源, 扩展编码可以让平均每个信源符号的码长逼近熵限。
- 对有记忆信源, 利用符号间依赖性还可以进一步降低平均码长, 此时极限由 H_∞ 决定。

1.12 本章易错点

- **** 非奇异码 $\neq$ 唯一可译码 ****: 非奇异只看单个码字, 唯一可译要看码字串接后的拆分是否唯一。
- 即时码一定唯一可译, 但唯一可译码不一定即时。
- Kraft/McMillan 不等式看的是码长可行性, 不是对具体码组的充分判定。
- 定长编码定理中的无失真“几乎无失真”, 错误概率趋于 0; 平均码长界限定理和香农第一定理讨论的是无失真唯一可译码。
- 扩展编码能逼近熵限: 单符号编码有不到 1 个码元的冗余, N 次扩展后平均到每个信源符号, 冗余小于 $\frac{1}{N}$ 。