

| 03 编码

| 编码

本章讨论的是**无失真信源编码**：在不丢失信源信息的前提下，尽量去掉信源冗余，使传输或存储更有效。

| 变量约定

- 信源符号集大小： $q = |S|$
- 码元符号集大小： $r = |X|$
- 定长码的码长： l

Note

若无特别说明， $\log$ 默认以 2 为底，信息量单位为 bit；码元进制为 r 时，每个码元最多承载 $\log r$ bit 信息。

| 为什么要编码

信源中常常存在冗余。信源编码的目的，是把信源符号序列映射成码符号序列，通过压缩冗余来提高传输效率。

信源的统计冗余主要来自两个方面：

- **符号间相关性**：当前符号可以被前后符号部分预测。
- **概率分布不均匀性**：某些符号出现概率远大于另一些符号。

信源越**独立、均匀**，冗余度越低；信源越有记忆、越不均匀，可压缩空间越大。

| 信源编码模型

信源编码是将**信源符号序列**按一定数学规则映射成**码符号序列**的过程，例如摩斯电码。

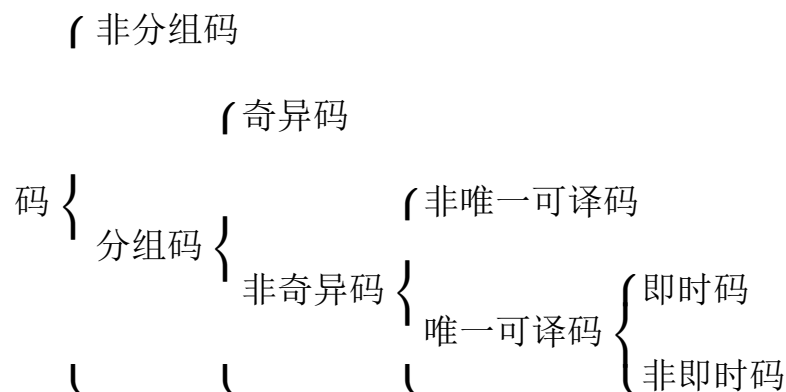
$$\begin{array}{ccccc} \text{信源符号集} & & \text{码元符号集} & & \text{码组} \\ S = \{s_1, s_2, \dots, s_q\} & \xrightarrow{\quad} & X = \{x_1, x_2, \dots, x_r\} & \xrightarrow{\quad} & C = \{W_1, W_2, \dots, W_q\} \end{array}$$

其中：

$$W_i = x_{i1}x_{i2} \cdots x_{il_i}$$

W_i 称为码字, l_i 称为码长。对 N 次扩展信源, 也可以建立 $S^N \leftrightarrow W^N$ 的映射。

码的分类



分组码

分组码把每个信源符号 s_i 映射成一个码字 W_i 。如果不同信源符号可能映射到同一个码字, 则会产生译码歧义。

奇异码与非奇异码

- **奇异码**: 至少存在两个不同信源符号对应同一个码字。
- **非奇异码**: 每个信源符号对应不同码字。

非奇异码只保证**单个码字**不混淆, 不一定保证一串码字连接起来后仍能唯一拆分。

唯一可译码

唯一可译码要求任意有限长的码符号序列, 最多只能被译成一种信源符号序列。

充要条件:

- 一个码是唯一可译码, 当且仅当它的任意次扩展码都是非奇异码。

重要结论:

- 非奇异码不一定是唯一可译码。
- 等长非奇异码一定是唯一可译码, 因为码字边界固定。

常用判别思路是构造后缀集合 (Sardinas-Patterson 判别法):

- 若迭代过程中出现空后缀, 或某个后缀恰好等于原码字, 则该码不是唯一可译码。
- 若后缀集合不再产生新元素, 且始终没有出现冲突, 则该码是唯一可译码。

| 即时码

即时码也叫前缀码。接收端在读到一个完整码字时，不需要参考后续码元就可以立即译码。

充要条件：

- 码组中任意一个码字都不是另一个码字的前缀。

例如 $C = \{0, 01\}$ 不是即时码。接收到 0 时，无法判断它就是码字 0，还是码字 01 的开头。

即时码可以用 r 进制码树构造：每个码字对应树上的一个叶节点，不能让某个码字落在另一个码字的祖先节点上。

| 定长码

定长码要求所有码字长度相同，设码长为 l 。若要把 q 个信源符号编码成 r 元非奇异码，必须满足：

$$r^l \geq q$$

对 N 次扩展信源 S^N 做定长编码时，信源序列共有 q^N 种，因此需要：

$$r^l \geq q^N$$

也就是：

$$\frac{l}{N} \geq \log_r q = \frac{\log q}{\log r}$$

| 平均码长与最佳码

对变长码而言，不同信源符号可以使用不同长度的码字。平均码长定义为：

$$\bar{L} = \sum_{i=1}^q p(s_i) l_i \quad \text{码元/信源符号}$$

在所有满足无失真要求的码中，平均码长最小的码称为最佳码，也常称紧致码。

| 定长编码定理

对离散无记忆信源 S 的 N 次扩展信源 S^N 进行 l 长定长编码。对于任意 $\varepsilon > 0$ ，只要满足：

$$\frac{l}{N} \geq \frac{H(S) + \varepsilon}{\log r}$$

当 $N \rightarrow \infty$ 时，就可以做到几乎无失真编码。

这里的“几乎无失真”不是完全无误，而是译码错误概率趋于 0。

证明思路：典型序列

先使用渐进均分性定理 (AEP)：

$$\lim_{N \rightarrow \infty} P \left\{ -\frac{1}{N} \log P(X^N) - H(S) < \varepsilon \right\} = 1$$

它说明当 N 足够大时，大部分概率质量集中在一批典型序列上。这些序列满足：

$$P(x^N) \approx 2^{-NH(S)}$$

因此典型序列个数大约为：

$$M_G \approx 2^{NH(S)}$$

为什么编码后近乎等概率分布

AEP 不只是说“典型序列很多”，更关键的是说：当 N 足够大时，真正可能出现的大部分序列都落在典型集中，并且每个典型序列的概率都近似为：

$$P(x^N) \approx 2^{-NH(S)}$$

也就是说，原信源单个符号可能很不均匀，但把它拉成长序列后，在承载主要概率质量的典型集中，各个典型序列几乎等概率。信源编码主要给这些典型序列分配码字，因此编码后的码字被选中的概率也近乎相等。

从冗余角度看，如果编码输出仍然明显不均匀或有相关性，就说明输出里还保留着可预测结构，还可以继续压缩。理想的高效信源编码会把这些冗余尽量去掉，使码元序列接近独立、等概率分布；这时每个码元平均承载的信息量才接近最大值 $\log r$ 。

更精确地说，在 ε 典型集 G_ε 中，典型序列个数可由 $2^{N[H(S)+\varepsilon]}$ 控制。只对典型序列进行定长编码，只需满足：

$$r^l \geq M_G$$

于是：

$$r^l \geq 2^{N[H(S)+\varepsilon]}$$

两边取对数：

$$l \log r \geq N[H(S) + \varepsilon]$$

得到：

$$\frac{l}{N} \geq \frac{H(S) + \varepsilon}{\log r}$$

非典型序列被舍弃。虽然它们一旦出现就会译码错误，但当 $N \rightarrow \infty$ 时，非典型序列的总概率趋于 0，因此错误概率：

$$p_E = P(\overline{G_\varepsilon}) \rightarrow 0$$

对于离散有记忆信源，也有类似结论，但应把 $H(S)$ 换为极限熵 H_∞ 。

典型序列概率的推导 >

对无记忆信源：

$$P(x^N) = \prod_{i=1}^N P(x_i)$$

取对数并除以 N ：

$$-\frac{1}{N} \log P(x^N) = \frac{1}{N} \sum_{i=1}^N [-\log P(x_i)]$$

当 $N \rightarrow \infty$ 时，由大数定律：

$$\frac{1}{N} \sum_{i=1}^N [-\log P(x_i)] \rightarrow E[-\log P(X)] = H(S)$$

所以典型序列满足：

$$P(x^N) \approx 2^{-NH(S)}$$

| 变长码

变长码通过给高概率符号分配短码字、给低概率符号分配长码字来降低平均码长。

| Kraft 不等式

存在一个 r 元即时码，其码长为 $l_1, l_2, \dots, l_q$ 的充分必要条件是：

$$\sum_{i=1}^q r^{-l_i} \leq 1$$

| McMillan 不等式

任意 r 元唯一可译码的码长都满足：

$$\sum_{i=1}^q r^{-l_i} \leq 1$$

反过来，只要一组码长满足这个不等式，就一定能构造出一组具有相同码长的即时码，因此也能构造唯一可译码。

⚠ Warning

Kraft/McMillan 不等式主要判断的是**码长集合是否可行**。

对某一个已经给出的具体码组，满足不等式不代表它本身一定是即时码或唯一可译码；但不满足不等式时，它一定不可能是即时码或唯一可译码。

| 编码信息率与编码效率

编码信息率表示平均每个码元实际承载的信源信息量：

$$R = \frac{H(S)}{\bar{L}} \quad \text{bit/码元}$$

由于 r 元码的每个码元最多承载 $\log r$ bit，编码效率为：

$$\eta = \frac{R}{\log r} = \frac{H(S)}{\bar{L} \log r} = \frac{H_r(S)}{\bar{L}}$$

其中：

$$H_r(S) = \frac{H(S)}{\log r}$$

信源编码的目标可以理解为：减小 $\bar{L}$ ，提高 R 和 η 。

| 平均码长界限定理

总可以找到一种无失真信源编码，构成唯一可译码，使平均码长满足：

$$\frac{H(S)}{\log r} \leq \bar{L} < \frac{H(S)}{\log r} + 1$$

该定理说明：

- 平均码长的理论下界是 $H_r(S) = \frac{H(S)}{\log r}$ 。
- 单符号变长编码最多只比熵限多不到 1 个码元。
- 这里是完全无失真编码，不是“几乎无失真”。

下界证明

由平均码长定义：

$$\begin{aligned} H(S) - \bar{L} \log r &= - \sum_{i=1}^q p(s_i) \log p(s_i) - \sum_{i=1}^q p(s_i) l_i \log r \\ &= - \sum_{i=1}^q p(s_i) \log p(s_i) + \sum_{i=1}^q p(s_i) \log r^{-l_i} \\ &= \sum_{i=1}^q p(s_i) \log \frac{r^{-l_i}}{p(s_i)} \end{aligned}$$

利用 $\log$ 函数的上凸性（Jensen 不等式）：

$$\begin{aligned} \sum_{i=1}^q p(s_i) \log \frac{r^{-l_i}}{p(s_i)} &\leq \log \sum_{i=1}^q p(s_i) \frac{r^{-l_i}}{p(s_i)} \\ &= \log \sum_{i=1}^q r^{-l_i} \\ &\leq 0 \end{aligned}$$

因此：

$$H(S) - \bar{L} \log r \leq 0$$

所以：

$$\bar{L} \geq \frac{H(S)}{\log r}$$

上界构造

取码长：

$$l_i = \lceil -\log_r p(s_i) \rceil$$

则：

$$-\log_r p(s_i) \leq l_i < -\log_r p(s_i) + 1$$

两边乘以 $p(s_i)$ 后求和：

$$\frac{H(S)}{\log r} \leq \bar{L} < \frac{H(S)}{\log r} + 1$$

同时这组码长满足 Kraft 不等式，因此可以构造即时码。

香农第一定理

香农第一定理也叫变长无失真信源编码定理。

对离散无记忆信源的 N 次扩展信源 S^N 进行编码，总能找到一种唯一可译码，使：

$$\frac{H(S)}{\log r} \leq \frac{\bar{L}_N}{N} < \frac{H(S)}{\log r} + \frac{1}{N}$$

证明很直接：把 S^N 看作一个新信源，套用平均码长界限定理：

$$\begin{aligned} \frac{H(S^N)}{\log r} &\leq \bar{L}_N < \frac{H(S^N)}{\log r} + 1 \\ \frac{NH(S)}{\log r} &\leq \bar{L}_N < \frac{NH(S)}{\log r} + 1 \\ \frac{H(S)}{\log r} &\leq \frac{\bar{L}_N}{N} < \frac{H(S)}{\log r} + \frac{1}{N} \end{aligned}$$

当 $N \rightarrow \infty$ 时：

$$\lim_{N \rightarrow \infty} \frac{\bar{L}_N}{N} = \frac{H(S)}{\log r} = H_r(S)$$

推广到一般离散平稳信源：

$$\lim_{N \rightarrow \infty} \frac{\bar{L}_N}{N} = \frac{H_\infty}{\log r}$$

这说明：

- 对无记忆信源，扩展编码可以让平均每个信源符号的码长逼近熵限。
- 对有记忆信源，利用符号间依赖性还可以进一步降低平均码长，此时极限由 H_∞ 决定。

本章易错点

- **非奇异码 $\neq$ 唯一可译码**：非奇异只看单个码字，唯一可译要看码字串接后的拆分是否唯一。
- **即时码一定唯一可译，但唯一可译码不一定即时。**

- Kraft/McMillan 不等式看的是码长可行性，不是对具体码组的充分判定。
- 定长编码定理中的无失真是“几乎无失真”，错误概率趋于 0；平均码长界限定理和香农第一定理讨论的是无失真唯一可译码。
- 扩展编码能逼近熵限：单符号编码有不到 1 个码元的冗余， N 次扩展后平均到每个信源符号，冗余小于 $\frac{1}{N}$ 。